

Proposta de Projeto

Predição de Recompra e Análise de Fidelidade no E-commerce: Uma Abordagem Híbrida de Padrões Frequentes e Classificação Interpretável.

Mineração de Dados

João Marcos Oliveira Neves

Matrícula: 2024008644

joao-neves@ufmg.br

Júlia Borba Fonseca de Souza

Matrícula: 2023117580

juliabfs@ufmg.br

Laura Martins Froede

Matrícula: 2023087877

froede@ufmg.br

Matheus Soares dos Santos de

Freitas

Matrícula: 2024080043

matheussdsf@ufmg.br

28 de abril de 2026

Conteúdo

1	Contexto e Motivação	2
2	Objetivos e Problema a ser investigado	2
3	Método Principal	2
3.1	Mineração de Padrões Frequentes na Engenharia de Atributos	2
3.2	Técnicas de Modelagem (Classificação)	3
3.3	Métricas	3
4	Dados Pretendidos	3
5	Metodologia Preliminar (Detalhamento via CRISP-DM)	4
6	Diretrizes de IA Responsável	5
6.1	Explicabilidade (Explainability)	5
6.2	Eficiência e Escalabilidade (Efficiency and Scalability)	6

1 Contexto e Motivação

A retenção de usuários e a antecipação de necessidades são pilares centrais do e-commerce moderno. No setor de mantimentos (*grocery*), o comportamento de compra é marcadamente cíclico e rotineiro. Nesse contexto, sistemas que operam apenas como "caixa-preta" falham em explicar a periodicidade e a intenção por trás da reposição de itens. Nesse sentido, a mineração de dados permite transformar registros transacionais em regras lógicas, otimizando o gerenciamento de inventário e a personalização da interface para reduzir o tempo de jornada de compra do usuário.

2 Objetivos e Problema a ser investigado

O problema central consiste em identificar a probabilidade de um produto já adquirido ser incluído na próxima cesta do usuário. Diferente de recomendações de descoberta (novos itens), a predição de recompra foca na manutenção do hábito. Formulamos três hipóteses:

- **Hipótese 1 (Sinergia de Recompra):** Existem conjuntos de produtos que, quando comprados juntos uma vez, tendem a ser recomprados em bloco na próxima transação (ex: café e leite)?
- **Hipótese 2 (Sensibilidade Temporal):** O intervalo de tempo `days_since_prior_order` é um preditor mais forte para a recompra de itens perecíveis (frutas/leite) do que para itens de limpeza?
- **Hipótese 3 (Fidelidade de Categoria):** Usuários que mantêm padrões sequenciais de compra em departamentos específicos (ex: Orgânicos) tendem a apresentar uma taxa de recompra (`reorder_rate`) superior à média da plataforma?

3 Método Principal

O projeto utiliza uma abordagem híbrida: extraímos o comportamento estrutural coletivo via Mineração de Padrões Frequentes para alimentar um modelo de Classificação, que é o método principal.

3.1 Mineração de Padrões Frequentes na Engenharia de Atributos

Em vez de usar apenas dados brutos (como o ID do produto), utilizaremos a Mineração de Conjuntos Frequentes para criar novos atributos (*features*) que capturam a relação entre produtos. Para tal, utilizaremos o algoritmo FP-Growth para identificar quais produtos costumam "andar juntos" (*itemsets* frequentes). Ademais, para cada par (Usuário, Produto), criaremos um atributo numérico baseado no Lift ou Confiança das regras de associação. Por exemplo: se um usuário coloca "Café" no carrinho, e o padrão frequente {Café, Filtro de Papel} tem um Lift de 5.0, o atributo "Afinidade de Cesta" para o item "Filtro de Papel" será alto naquela sessão, aumentando a probabilidade de recompra prevista pelo classificador.

Cabe ressaltar que a unidade de predição do modelo não é uma linha de transação isolada, mas sim o par (Usuário, Produto) na próxima cesta do cliente. Além disso, para garantir a integridade da validação e evitar o vazamento de dados, a mineração dos conjuntos frequentes e o cálculo das métricas de Lift ou Confiança serão aplicados exclusivamente no conjunto de treino.

3.2 Técnicas de Modelagem (Classificação)

Para a modelagem, serão aplicados modelos de Ensemble baseados em árvores, como Random Forest ou Gradient Boosting. O uso desses algoritmos se justifica por lidarem excelentemente com relações não lineares entre os atributos e serem superiores a uma árvore de decisão simples em termos de generalização, mantendo a capacidade de extração de conhecimento em prol da Explicabilidade. Já a Regressão Logística servirá como baseline comparativo por ser um modelo linear simples e interpretável, permitindo avaliar se a inclusão de atributos complexos de associação e modelos não lineares traz um ganho real de performance em relação a uma abordagem estatística clássica.

3.3 Métricas

Dada a natureza desbalanceada do dataset Instacart, onde a classe de recompra é minoritária, a escolha das métricas é crítica para evitar interpretações enviesadas. A avaliação será centralizada na PR-AUC (*Precision-Recall AUC*), que servirá como a métrica mestre de performance por ser mais informativa que a curva ROC em cenários de alta esparsidade, focando diretamente na eficácia do modelo em prever a classe positiva. Complementarmente, utilizaremos o tripé:

- **Precisão (Precision):** Essencial para garantir a assertividade das recomendações, minimizando o "spam" de sugestões irrelevantes que poderiam prejudicar a experiência do usuário.
- **Revocação (Recall):** Crucial para o objetivo de negócio, visando capturar o maior volume possível de itens que o cliente realmente pretende recomprar, facilitando sua jornada de reposição.
- **F1-Score:** Utilizado como a média harmônica para equilibrar o trade-off entre precisão e revocação, oferecendo uma visão única da robustez do classificador.

Por fim, a Importância de Atributos (*Feature Importance*) será empregada não apenas como métrica de erro, mas como ferramenta de descoberta. Ela permitirá validar as hipóteses do projeto ao identificar se variáveis temporais (sazonalidade) ou de taxonomia (fidelidade de categoria) possuem maior peso na decisão do modelo.

4 Dados Pretendidos

O conjunto de dados a ser investigado é a base Instacart Market Basket Analysis, um dataset relacional que descreve a jornada de compra de clientes reais ao longo do tempo.

A base compreende mais de 3 milhões de pedidos realizados por cerca de 200 mil usuários, totalizando mais de 32 milhões de registros de transações.

Diferente de datasets estáticos, a estrutura da Instacart permite a reconstrução sequencial do histórico de cada cliente, sendo fundamental para o problema de predição de recompra. O processamento envolverá a integração dos seguintes arquivos principais:

- **orders.csv** (Contexto Temporal): Atua como a espinha dorsal do dataset. Contém o identificador da ordem (`order_id`), do usuário (`user_id`), o dia da semana (`order_dow`), a hora do dia (`order_hour_of_day`) e, crucialmente, o campo `days_since_prior_order`, que permite mensurar a latência entre compras — variável crítica para a Hipótese 2 (Sensibilidade Temporal).
- **order_products__prior.csv** (Histórico de Transações): Contém o conteúdo detalhado de cada cesta anterior. Para cada item, informa o `product_id`, a ordem de inclusão no carrinho e a variável alvo `reordered` (indicação binária se o item já foi comprado pelo usuário anteriormente).
- **products.csv** (Metadados): Fornece o nome semântico dos produtos e faz a ponte com as categorias. É essencial para a diretriz de Explicabilidade, permitindo que o modelo traduza IDs numéricos em categorias compreensíveis como "Leite Integral" ou "Detergente".
- **aisles.csv** e **departments.csv** (Categorização): Agrupam os produtos em corredores (ex: "Iogurtes") e departamentos (ex: "Laticínios e Ovos"). Esses dados serão utilizados para validar a Hipótese 3 (Fidelidade de Categoria) e reduzir a dimensionalidade do espaço de produtos.

5 Metodologia Preliminar (Detalhamento via CRISP-DM)

A execução do projeto seguirá as fases do modelo CRISP-DM, garantindo um ciclo de análise sistemático e repetível:

- **Entendimento do Negócio (Business Understanding):** Foco em traduzir a meta de fidelização de clientes em um problema de classificação binária. O sucesso será medido pela capacidade do modelo em superar um baseline de Regressão Logística, priorizando métricas que penalizem o falso positivo (como Precisão e PR-AUC), garantindo que as recomendações de recompra sejam assertivas e úteis para a jornada do usuário.
- **Entendimento dos Dados (Data Understanding):** Envolverá uma Análise Exploratória de Dados (EDA) para mapear a esparsidade da relação usuário-produto e a distribuição de "cauda longa" do catálogo. Será verificada a distribuição estatística de `days_since_prior_order` para identificar janelas de consumo e a detecção de *outliers* (ex: usuários com comportamento de compra por atacado), garantindo que a base final reflita o comportamento do consumidor médio de varejo.
- **Preparação dos Dados (Data Preparation)**

- **Separação Temporal:** Isolamento da última cesta de cada usuário para o conjunto de teste antes da criação das *features*, mitigando o risco de vazamento de dados (*data leakage*).
- **Amostragem Estratificada:** Seleção de uma amostra representativa de usuários que preserve a proporção da classe alvo (**reordered**) e a diversidade de departamentos.
- **Engenharia de Atributos:**
 - * **Usuário:** Cálculo da média de dias entre pedidos e taxa de recompra histórica.
 - * **Produto:** Extração da probabilidade global de recompra e volume total de vendas.
 - * **Interação:** Criação de variáveis de afinidade, como o número de vezes que o usuário X comprou o produto Y e o intervalo desde a última interação.
 - * **Integração de Padrões:** Inclusão de métricas de Lift e Confiança (via FP-Growth) como colunas preditivas para o classificador.
- **Modelagem (Modeling):** Aplicação de modelos de Ensemble (Random Forest ou Gradient Boosting) sobre os dados preparados. Nesta fase, serão aplicadas estratégias de calibração de limiar para lidar com o desbalanceamento da base, além da implementação do FP-Growth com poda de suporte mínimo para otimização de memória.
- **Avaliação (Evaluation):** Análise técnica e semântica dos resultados. As previsões serão confrontadas com as hipóteses iniciais. Por exemplo, para a Hipótese 2 (Sensibilidade Temporal), será analisado se a Importância de Atributos confirma que a variável de dias desde a última compra é mais determinante para itens perecíveis do que para produtos de limpeza.

6 Diretrizes de IA Responsável

Nesta seção, detalhamos a aplicação das diretrizes éticas e responsáveis no ciclo de mineração de dados, especificamente na interação com o modelo de linguagem (LLM) que auxiliará no desenvolvimento do modelo de predição de recompra.

6.1 Explicabilidade (Explainability)

- **Pertinência:** Diferente de recomendações de descoberta, a predição de recompra lida com a rotina e o hábito. Entender se um item foi sugerido devido ao intervalo de tempo (sazonalidade), à frequência histórica ou à afinidade de cesta (padrão frequente) é vital para que gestores de e-commerce validem a lógica do algoritmo e evitem sugestões intrusivas ou sem sentido para o consumidor.
- **Como explicitar nos prompts para a LLM:** No estágio de análise e geração de relatórios, a LLM será instruída com a seguinte diretriz: *"Atue como um especialista em comportamento do consumidor. Para cada predição de recompra ou regra de*

associação identificada, você não deve apenas reportar IDs e probabilidades; você deve cruzar esses dados com os nomes dos produtos e categorias (`products.csv` e `aisles.csv`) para construir uma justificativa lógica sobre o hábito do usuário (ex: correlacionar a compra de itens de café da manhã com a reposição de laticínios)."

- **Aspectos da solução que se espera observar:** A transição de uma saída puramente numérica (0 ou 1) para uma camada de inteligência de negócio. O sistema deixará de apenas "prever" para passar a "explicar" a intenção de compra, permitindo a segmentação estratégica de clientes com base em suas motivações de consumo.
- **Evidências esperadas:** Relatórios qualitativos que descrevam perfis de consumo identificados pelo modelo, como "Repositor de Essenciais de Hortifruti" ou "Comprador de Conveniência de Fim de Semana", em vez de meras tabelas de `product_id` e métricas de erro.
- **Benefícios:** Aumento da transparência nas decisões de marketing e facilitação do uso dos dados por equipes não técnicas, que podem utilizar os "porquês" gerados pela IA para planejar campanhas e promoções personalizadas.
- **Trade-offs:** A tradução narrativa via LLM pode introduzir interpretações excessivamente criativas que mascaram o rigor estatístico. Para mitigar esse risco, toda explicação semântica deverá ser acompanhada das métricas originais do modelo (Importância de Atributos, Lift e F1-Score) para fins de auditoria técnica.

6.2 Eficiência e Escalabilidade (Efficiency and Scalability)

- **Pertinência:** O processamento de grandes volumes de dados (*Big Data*), como os 32 milhões de registros da Instacart, impõe desafios de viabilidade técnica. Algoritmos de mineração de padrões como o FP-Growth podem sofrer de explosão combinatória se não houver um controle estrito do espaço de busca. Sem otimizações de memória e tempo de execução, o sistema torna-se excessivamente custoso, lento e potencialmente inviável para aplicações em tempo real.
- **Como explicitar nos prompts para a LLM:** No estágio de desenvolvimento do código e arquitetura, a LLM será instruída com a seguinte diretriz: *"Atue como um Arquiteto de Dados focado em alta performance. Ao gerar scripts de manipulação de dados para a base Instacart, você deve priorizar a vetorização de operações e a otimização de tipos primitivos (ex: converter strings repetitivas em `category` e IDs em `int32`). Além disso, sugira critérios de amostragem estratificada e poda de suporte mínimo que garantam a execução do modelo em hardware acadêmico padrão sem perda de representatividade estatística."*
- **Aspectos da solução que se espera observar:** Uma infraestrutura de dados otimizada onde o tempo de processamento cresce de forma controlada. A solução passará de um processamento pesado e linear para uma abordagem de Mineração Ágil, onde apenas os dados necessários para validar as hipóteses de negócio são mantidos em memória RAM.

- **Evidências esperadas:** Logs de execução demonstrando a redução no consumo de memória (ex: de dezenas de GBs para poucos GBs) e a utilização de técnicas de *sampling* que mantenham a distribuição original das classes de recompra, permitindo ciclos de experimentação mais rápidos.
- **Benefícios:** Redução de custos computacionais, maior velocidade na geração de *insights* e a possibilidade de escalar o modelo para bases ainda maiores no futuro, garantindo uma solução de IA sustentável e econômica.
- **Trade-offs:** A busca por eficiência máxima pode levar ao uso de filtros de suporte muito restritivos, o que arrisca a perda de "padrões de cauda longa" (comportamentos de nicho raros, mas valiosos). O trade-off central reside no equilíbrio entre a economia de recursos computacionais e a profundidade/exaustividade da análise dos dados.

Referências

- [1] Agrawal, R. et al. (1994). Fast algorithms for mining association rules. *VLDB*.
- [2] Instacart. (2017). The Instacart Online Grocery Shopping Dataset.
- [3] Witten, I. H., et al. (2016). Data Mining: Practical Machine Learning Tools and Techniques.