

Relatório de Projeto

Mineração de Dados

ICE144

João Marcos Oliveira Neves
Matrícula: 2024008644
joao-neves@ufmg.br

Júlia Borba Fonseca de Souza
Matrícula: 2023117580
juliabfs@ufmg.br

Laura Martins Froede
Matrícula: 2023087877
froede@ufmg.br

Matheus Soares dos Santos de Freitas
Matrícula: 2024080043
matheussdsf@ufmg.br

30 de junho de 2026

Conteúdo

1	Introdução	1
2	Trabalhos Relacionados	1
2.1	Modelos de <i>Gradient Boosting</i> (GBDT)	2
2.2	Arquiteturas e Métodos Alternativos	2
2.3	Arquiteturas e Métodos Alternativos	2
3	Metodologia	3
3.1	Caracterização do Dataset	3
3.2	Preparação e Análise Exploratória dos Dados	3
3.3	Diagnóstico de Qualidade	3
3.4	Exploração para Validação de Hipóteses	4
3.5	Tratamento de Dados	5
3.6	Metodologia de Modelagem: Abordagem Híbrida	7
3.6.1	Mineração de Padrões Frequentes (<i>FP-Growth</i>)	7
3.6.2	Abordagem Estática: Modelagem de Preferências de Longo Prazo	8
3.6.3	Abordagem Session-Based (Dinâmica)	9
3.7	Métricas de Avaliação	9
4	Implementação	9
4.1	Ferramentas e Bibliotecas	10
4.2	Pipeline de Preparação de Dados	10
4.2.1	Tratamento de Valores Ausentes	10
4.2.2	Remoção de Colunas Não-Informativas	10
4.2.3	Construção da Tabela Analítica	10
4.3	Implementação de Mineração de Padrões (<i>FP-Growth</i>)	11
4.4	Execução do Algoritmo	11
4.5	Geração de Features de Afinidade	11

4.5.1	Limitações Identificadas na Abordagem Estática	11
4.5.2	Implementação de Modelagem Preditiva	11
4.5.3	Abordagem Estática: Modelagem de Preferências Históricas	11
4.5.4	Transição Metodológica: Da Abordagem Estática para Session-Based	12
4.5.5	Abordagem Session-Based com Contexto Dinâmico	12
4.6	Decisões Técnicas e Justificativas	12
4.7	Etapas do Pipeline e Orquestração	12
5	Integração das Diretrizes de IA Responsável e Aspectos Éticos	13
5.1	Explicabilidade e Transparência	13
5.2	Mitigação de Viés e Equidade	13
5.3	Eficiência e Sustentabilidade	14
5.4	Trade-offs na Avaliação e Experiência do Usuário	14
6	Análise e Discussão dos Resultados Experimentais	14
6.1	Mineração de Padrões Frequentes: Validação da Hipótese 1	14
6.2	Abordagem Estática (Longo Prazo)	15
6.3	Abordagem Dinâmica (<i>Session-Based</i>)	17
6.4	Limitações dos Resultados	20
7	Conclusões e Perspectivas	21
7.1	Principais Conquistas	21
7.2	Limitações e Trabalhos Futuros	21

1 Introdução

O comércio eletrônico de alimentos, liderado por plataformas como o Instacart, tem na personalização e na antecipação de necessidades os pilares para a retenção de clientes. Este projeto utiliza o dataset *Instacart Market Basket Analysis* — composto por cerca de 32 milhões de transações — para explorar a mineração de padrões de consumo e a identificação de associações significativas entre produtos.

O objetivo central é aplicar algoritmos de mineração de dados para descobrir afinidades entre itens, permitindo a antecipação de compras e a segmentação de clientes. Paralelamente, o trabalho reflete sobre o rigor ético na análise de dados, integrando diretrizes de IA Responsável — como explicabilidade, eficiência computacional e transparência — no desenvolvimento de uma solução técnica que equilibra robustez analítica e uso apropriado de dados comportamentais.

2 Trabalhos Relacionados

O desafio de predição no dataset *Instacart* concentra-se na modelagem de consumo esparsa e na otimização de métricas não lineares (F1-Score). A literatura destaca três pilares de resultados:

2.1 Modelos de *Gradient Boosting* (GBDT)

Modelos GBDT são o estado da arte para pontuação de propensão:

- **XGBoost:** [5] Implementações de destaque, como a de Kazuki Onodera (2º lugar na competição), alcançaram um F1-Score de 0,407 utilizando modelos distintos para cenários de compra e inatividade.
- **LightGBM:** [3] Preferido pela alta eficiência de memória e velocidade, é o padrão para *ensembles* e escalabilidade em grandes bases.
- **CatBoost:** Utilizado para mitigar *overfitting* devido ao seu tratamento nativo e superior para variáveis de alta cardinalidade.

2.2 Arquiteturas e Métodos Alternativos

Estudos comparativos demonstram variações significativas de performance:

- **Modelos Estatísticos:** Segmentar usuários por volume de pedidos provou ser crucial; modelos lineares (Regressão Logística, AdaBoost) apresentam um teto de performance ($F1 \approx 0,29$) inferior aos GBDTs.
- **Deep Learning:** Soluções de alta performance (ex.: 3º lugar no Kaggle) utilizam redes neurais profundas para capturar padrões não lineares complexos, mas exigem elevado custo computacional.
- **Regras de Associação:** Estudos como o de Stanford (CS229) destacam a dificuldade de integrar regras estáticas de afinidade em modelos de recompra dinâmica — uma limitação que este trabalho supera ao utilizar o *FP-Growth* como extrator de *features* dinâmicas.

2.3 Arquiteturas e Métodos Alternativos

Além do *boosting*, a literatura explora abordagens para capturar diferentes nuances do comportamento do consumidor:

- **Modelos Estatísticos e Redes Neurais:** Enquanto modelos lineares e clássicos (Regressão Logística, AdaBoost) apresentam limitações de performance, arquiteturas de *Deep Learning* capturam padrões complexos, porém exigem infraestrutura computacional intensiva.
- **Regras de Associação:** Estudos como o da Universidade de Stanford exploram a afinidade entre produtos, embora relatem dificuldades em integrar regras estáticas à predição dinâmica. O presente trabalho endereça esta lacuna utilizando o algoritmo *FP-Growth* [4] como extrator dinâmico de *features*, refinando o contexto da cesta de compras.

3 Metodologia

Este projeto adota uma abordagem híbrida estruturada pela metodologia CRISP-DM, composta por quatro eixos principais: **Entendimento de Negócio**, **Preparação dos Dados** (diagnóstico de qualidade dos dados, EDA e tratamento), **Modelagem** (mineração de padrões frequentes (*FP-Growth*) e modelagem preditiva via *Gradient Boosting*) e **Avaliação**. A investigação testa se o comportamento de compra (recompra em bloco), o intervalo temporal e a heterogeneidade por departamentos influenciam a propensão de recompra, mantendo sempre o rigor ético de uma IA Responsável (foco em explicabilidade e eficiência).

3.1 Caracterização do Dataset

Utilizamos uma amostra estratificada de 10% do dataset *Instacart Market Basket Analysis* [2], totalizando aproximadamente 3,24 milhões de registros, visando o equilíbrio entre representatividade estatística e viabilidade computacional. Os dados estruturam-se no nível de pares (usuário, produto), onde a variável-alvo *reordered* indica se um item foi recomprado em uma transação posterior. As principais métricas do conjunto de dados são:

- **Escopo:** 130 mil usuários e 50 mil produtos distribuídos em 21 departamentos.
- **Conteúdo:** Metadados de pedidos, histórico temporal e indicadores operacionais de inserção na cesta.
- **Distribuição:** O desbalanceamento de classes é acentuado, com taxas de recompra variando conforme o perfil do usuário e a categoria do produto, exigindo modelos sensíveis a essa disparidade.

3.2 Preparação e Análise Exploratória dos Dados

3.3 Diagnóstico de Qualidade

A análise de integridade dos dados confirmou:

- **Valores Ausentes:** Os nulos na variável `days_since_prior_order` (6,39%) correspondem exclusivamente aos primeiros pedidos (`order_number` = 1). Foram mantidos com imputação estratégica para evitar viés amostral.
- **Distribuições:** A alta assimetria e a lei de potência na frequência dos itens (cauda longa) confirmam a necessidade do *FP-Growth*, que extrai associações relevantes mesmo sob distribuição desigual.
- **Consistência:** A ausência de duplicatas é garantida pela unicidade da chave composta `order_id` + `product_id`.

3.4 Exploração para Validação de Hipóteses

O projeto foi estruturado em torno de três hipóteses principais, cada uma guiando uma frente de análise exploratória:

Hipótese 1 (Sinergia de Recompra): *"Existem conjuntos de produtos que, quando comprados juntos uma vez, tendem a ser recomprados em bloco na próxima transação?"*

Análise: Esta questão impulsionou a análise de padrões frequentes e o cálculo de métricas de associação (suporte, confiança, lift). A exploração visual mapeou quais combinações de produtos exibem força associativa significativa.




Figura 1: Distribuição do tamanho das cestas de compras.




Figura 2: Produtos mais frequentes.

Hipótese 2 (Sensibilidade Temporal): *"O intervalo de tempo (`days_since_prior_order`) atua como preditor mais forte para produtos perecíveis e de alto giro do que para categorias especializadas?"*




Figura 3: Taxa média de recompra.




Figura 4: Distribuição acumulada de dias entre pedidos por departamento.

Análise: Os gráficos anteriores mostram a distribuição de dias e a taxa global de recompra separadamente. O que a hipótese exige é ver as duas coisas juntas, por tipo de departamento: a curva de recompra dos perecíveis cai de forma diferente da dos não perecíveis à medida que aumentam os dias?

Análises cruzadas entre departamento e intervalo temporal revelaram taxas de recompra heterogêneas: itens de reabastecimento frequente (ex: laticínios) mostram dependência clara do intervalo temporal, enquanto categorias especializadas exibem padrões mais voláteis.

Hipótese 3 (Fidelidade de Categoria): *"Que departamentos apresentam taxas de recompra e desbalanceamento discrepantes, e como isto influi na estratégia de modelagem?"*

Análise: Gráficos de distribuição revelaram que alguns departamentos concentram percentuais muito mais elevados de recompras (ex: laticínios, bebidas) em comparação com outros (ex: artigos de saúde, beleza), justificando modelos sensíveis às características categoriais dos produtos.

3.5 Tratamento de Dados

Remoção de Colunas: A coluna `eval_set`, que sinalizava a partição original do Instacart (valor único: `"prior"`), foi removida por não contribuir discriminatoriamente ao modelo. As colunas identificadoras (`order_id`, `user_id`, `product_id`, `aisle_id`, `depart-`




Figura 5: Taxa de recompra por dias entre o último pedido entre perecíveis e não perecíveis.




Figura 6: Sensibilidade temporal por departamento.




Figura 7: Distribuição da variável resposta.

ment_id) foram mantidas no pipeline de processamento, necessárias para agrupamentos e construção de features, mas excluídas das partições de treino do classificador final.

Imputação de Valores Ausentes: A coluna *days_since_prior_order* foi tratada com duas estratégias: Inserção de um valor sentinela (-1) para pedidos iniciais (*order_number* = 1), criando explicitamente uma feature que indica ‘primeira compra’, além da criação de uma feature binária auxiliar *is_first_order* para facilitar a captura desta transição importante.

Normalização e Escala: Features contínuas foram padronizadas quando apropriado, especialmente antes do treinamento de modelos de gradient boosting (LightGBM).

3.6 Metodologia de Modelagem: Abordagem Híbrida

A estratégia de modelagem evoluiu de uma abordagem puramente estática (análise agregada do histórico do usuário) para uma abordagem híbrida dinâmica, integrando contexto de sessão com regras de afinidade. Esta evolução foi motivada pelos resultados limitados da primeira etapa, reconhecendo que a predição de recompra exige capturar tanto padrões latentes de longo prazo quanto sinais imediatos de intenção de compra.

3.6.1 Mineração de Padrões Frequentes (*FP-Growth*)

Objetivo e Aplicação: Extrair regras de associação entre produtos[4], respondendo à pergunta ‘quais itens tendem a ser comprados juntos?’ O algoritmo *FP-Growth* foi escolhido pela eficiência em dados de alta dimensionalidade, construindo uma árvore compacta (*FP-tree*) que evita o custo computacional do *Apriori* tradicional.




Figura 8: Taxa de recompra por departamento.

Protocolo de Execução:

- Mineração realizada exclusivamente sobre o histórico de pedidos anteriores (*prior*), garantindo ausência de data leakage em relação aos conjuntos de treino e teste,
- Limiares de suporte e confiança ajustados para capturar associações comercialmente relevantes, eliminando ruído da cauda longa de produtos raros,
- Extração de três métricas principais para cada par de produtos: Suporte (frequência relativa de co-ocorrência); Confiança: probabilidade condicional (se A é comprado, qual a probabilidade de B?); Lift (razão entre a confiança observada e a esperada por acaso, sinalizando força da associação)

Transformação em Features: As regras de afinidade foram quantificadas e agregadas em features numéricas (*fp_basket_max_lift*, *fp_basket_sum_confidence*, etc.), sinalizando se um produto candidato integrava associações significativas com outros itens já presentes na cesta histórica do usuário.

3.6.2 Abordagem Estática: Modelagem de Preferências de Longo Prazo

Conceito: "O que o usuário costuma comprar?" A abordagem estática extrai padrões repetitivos do vasto histórico transacional, construindo probabilidades fixas de recompra independentemente do contexto imediato.

Features Construídas:

- Atributos de Frequência Individual: Taxa de recompra histórica por usuário (*user_reorder_rate*); taxa de recompra histórica por produto (*product_reorder_rate*); número de compras anteriores do usuário (*user_n_prior_orders*) e dias médios entre recompras por usuário.

- Atributos de Afinidade (derivados de FP-Growth): Máximo lift das regras envolvendo o produto candidato; soma de confianças de associações relevantes e indicadores de co-compra com produtos já adquiridos
- Atributos de Contexto Categórico: Departamento e corredor do produto; taxa de recompra agregada por departamento e características sazonais (quando aplicável)

Classificador: Treinamento de um modelo LightGBM (gradient boosting) sobre a tabela analítica construída no nível (*user_id*, *product_id*). O modelo foi otimizado para maximizar o F1-Score através de calibração iterativa do threshold de decisão, validação cruzada estratificada por usuário e análise de importância de features para interpretabilidade.

Limitação Identificada: Embora capturasse padrões de longo prazo, a abordagem estática resultou em precisão moderada, sugerindo que a intenção momentânea de compra (dinâmica de sessão) era um sinal igualmente ou mais relevante.

3.6.3 Abordagem Session-Based (Dinâmica)

Conceito: Integrar o contexto imediato da transação atual, capturando ‘*quais produtos o usuário provavelmente incluirá nesta sessão específica?*’. A modelagem session-based reconhece que o comportamento de compra é influenciado tanto por padrões históricos quanto por circunstâncias imediatas (tipo de dia, hora, sazonalidade, tamanho da cesta presente).

3.7 Métricas de Avaliação

A avaliação foi conduzida mediante métricas apropriadas para problemas de classificação binária desbalanceados [1]:

Precision (Precisão): Taxa de acertos entre as predições positivas. Crítica para evitar recomendações irrelevantes que comprometem a experiência do usuário.

Recall (Revocação): Taxa de casos positivos corretamente identificados. Essencial para garantir que oportunidades legítimas de recompra não são perdidas.

F1-Score: Média harmônica entre precisão e revocação, fornecendo um indicador agregado de desempenho que não favorece artificialmente a classe majoritária (não-recompra).

Importância de Features: Extração da contribuição relativa de cada atributo para a predição, permitindo interpretação e validação do modelo contra conhecimento de domínio.

4 Implementação

Este capítulo documenta a implementação da solução híbrida desenvolvida para predição de recompra no dataset *Instacart*. A implementação evoluiu iterativamente, começando por uma abordagem estática baseada em histórico agregado e evoluindo para um modelo session-based que captura o contexto dinâmico da sessão de compra. Ao longo do processo, integrou-se o algoritmo *FP-Growth* para mineração de padrões frequentes e o modelo *LightGBM* para classificação preditiva.

Repositório com o Projeto acessível pelo link: [Acessar Repositório GitHub](#)

Notebook Jupyter em que este Projeto foi executado: [Acessar Notebook do Projeto](#)

4.1 Ferramentas e Bibliotecas

A solução foi implementada em Python 3, utilizando as seguintes bibliotecas principais:

- Pandas e NumPy: Manipulação e análise de dados
- Scikit-learn: Pré-processamento, métricas de avaliação e validação cruzada
- MLxtend (FP-Growth): Mineração de padrões frequentes e geração de regras de associação
- LightGBM: Modelo de gradient boosting para classificação
- Matplotlib e Seaborn: Visualização de dados e resultados
- Jupyter Notebook: Documentação executável do código e análises

4.2 Pipeline de Preparação de Dados

4.2.1 Tratamento de Valores Ausentes

A coluna *days_since_prior_order* apresentava 207.017 registros nulos (6,39% do dataset), concentrados em pedidos iniciais (*order_number* = 1). Ao invés de remover estes registros, criou-se uma feature binária *is_first_order* para capturar explicitamente a transição de novo cliente. Para pedidos não-iniciais, valores nulos foram imputados com a mediana do intervalo observado (aproximadamente 7 dias).

4.2.2 Remoção de Colunas Não-Informativas

A coluna *eval_set* foi removida por apresentar valor único ("*prior*"), não agregando poder discriminatório. As colunas identificadoras (*order_id*, *user_id*, *product_id*) foram mantidas durante o pré-processamento para fins de agrupamento e rastreabilidade, mas excluídas das partições finais de treino do classificador.

4.2.3 Construção da Tabela Analítica

A tabela analítica foi construída no nível (*user_id*, *product_id*), gerando instâncias de treino a partir de:

Abordagem Estática: Cada par (*user_id*, *product_id*) presente no histórico (*prior*) foi marcado com label 1 se recomprado no conjunto train, e 0 caso contrário. Resultado: 130k usuários $\times$ 50k produtos únicos = tabela esparsa com 6M pares potenciais, dos quais apenas 570k efetivamente ocorrem no histórico

Abordagem Session-Based: para cada sessão de compra (*order_id*), geram-se instâncias (*user_id*, *product_id*) correspondentes a todos os produtos já adquiridos pelo usuário em compras anteriores. Cada instância foi marcada com label 1 se o produto foi recomprado nesta sessão específica, e 0 caso contrário. Resultado: tabela densa no nível de sessão, capturando o comportamento momentâneo.

4.3 Implementação de Mineração de Padrões (FP-Growth)

4.4 Execução do Algoritmo

O algoritmo FP-Growth foi aplicado ao conjunto de histórico (prior) para extrair conjuntos frequentes de produtos comprados juntos:

Parâmetros utilizados:

- Min Support: 0,001 (produtos devem aparecer em pelo menos 0,1% das transações)
- Min Confidence: 0,1 (regra $A \rightarrow B$ deve ter confiança mínima de 10%)
- Métrica de seleção: Lift (razão entre confiança observada e confiança esperada por acaso)

4.5 Geração de Features de Afinidade

As regras extraídas foram transformadas em features numéricas:

1: *fp_basket_max_lift*: Máximo lift observado entre o produto candidato e outros na cesta histórica

2: *fp_basket_sum_confidence*: Soma das confianças de todas as regras associadas ao produto

3: *fp_basket_sum_lift*: Soma dos lifts das regras

4: *fp_basket_rule_count*: Contagem de regras nas quais o produto participa.

Estas features foram incorporadas à tabela analítica através de lookup baseado em pares de produtos.

4.5.1 Limitações Identificadas na Abordagem Estática

Durante a experimentação, observou-se que as features de afinidade apresentaram baixa importância no modelo estático, sugerindo que regras de associação baseadas no histórico completo tinham valor preditivo reduzido quando aplicadas a previsões de longo prazo. Esta constatação motivou a transição para session-based.

4.5.2 Implementação de Modelagem Preditiva

4.5.3 Abordagem Estática: Modelagem de Preferências Históricas

Estratégia: Treinar um classificador LightGBM no nível (*user_id*, *product_id*) para prever se um par historicamente observado seria recomprado no próximo pedido, independentemente de contexto.

Features Principais:

- Histórico do Usuário: *user_reorder_rate_hist*, *user_unique_products*, *user_avg_basket_size*, *user_avg_days_between_orders*
- Histórico do Produto: *product_reorder_rate*, *product_avg_orders_per_user*, *product_market_penetration*
- Afinidade: Atributos FP-Growth listados acima

- Categóricos: *department, aisle*

Otimização de Threshold: O limiar de decisão padrão (0, 5) foi calibrado manualmente para maximizar o F1-Score, alterando a razão entre precisão e revocação conforme apropriado para o caso de uso.

4.5.4 Transição Metodológica: Da Abordagem Estática para Session-Based

Reconhecendo que a abordagem estática capturava apenas padrões de longo prazo e ignorava o contexto momentâneo da compra, implementou-se uma reformulação fundamental do problema:

De: *'Este usuário costuma recomprar este produto?'* (questão estática, resposta independente da sessão)

Para: *'Nesta sessão de compra específica, o usuário provavelmente incluirá este produto?'* (questão dinâmica, sensível ao contexto imediato)

Esta transição demandou:

1. Reconstrução da tabela analítica: Mudança do nível (*user_id, product_id*) agregado para o nível (*order_id, product_id*) desagregado
2. Redefinição do alvo: A variável-alvo passou a ser binária por sessão, não por usuário

4.5.5 Abordagem Session-Based com Contexto Dinâmico

Estratégia: Treinar um classificador LightGBM no nível (*order_id, product_id*) que prediz recompra considerando não apenas o histórico, mas também o estado momentâneo da cesta.

Modelo: LightGBM com validação cruzada estratificada por usuário, garantindo generalizabilidade.

Otimização de Threshold: Similar à abordagem estática, com calibração iterativa do limiar de decisão.

4.6 Decisões Técnicas e Justificativas

LightGBM: Selecionado por sua alta performance em grandes volumes de dados e robustez frente ao desbalanceamento de classes, comum no dataset Instacart. Além da eficiência, o modelo oferece interpretabilidade nativa via Feature Importance e permite o ajuste fino de limiares de decisão, garantindo flexibilidade na otimização de métricas.

Escolha de FP-Growth sobre Apriori: Preferido em relação ao Apriori por construir uma árvore compacta (*FP-tree*), eliminando a geração custosa de conjuntos de candidatos. Esta arquitetura reduz drasticamente o consumo de memória e garante a escalabilidade necessária para processar as dezenas de milhares de produtos únicos do catálogo.

4.7 Etapas do Pipeline e Orquestração

O pipeline completo seguiu as seguintes etapas:

1. Carregamento e Limpeza: Importação de CSVs, tratamento de valores ausentes, remoção de colunas não-informativas

2. Análise Exploratória: Diagnóstico de distribuições, desbalanceamento, correlações
3. Construção Estática: Tabela analítica agregada, features históricas, features FP-Growth
4. Treino Estático: LightGBM estático, calibração de threshold, avaliação
5. Análise de Insuficiência: Reconhecimento de que contexto dinâmico é necessário
6. Construção Session-Based: Reconstrução de tabela analítica desagregada, features dinâmicas
7. Treino Session-Based: LightGBM session-based, calibração de threshold
8. Ablação: Comparação com modelo “puro” para validar contribuição FP-Growth
9. Avaliação Final: Métricas consolidadas, análise de importância, documentação

5 Integração das Diretrizes de IA Responsável e Aspectos Éticos

O desenvolvimento deste sistema priorizou o equilíbrio entre eficácia preditiva, transparência e sustentabilidade, norteado por quatro pilares fundamentais:

5.1 Explicabilidade e Transparência

A escolha do *LightGBM* e do *FP-Growth* foi deliberada para garantir a rastreabilidade das decisões. Ao contrário de modelos "caixa-preta", estas ferramentas oferecem:

- **Auditoria de Sinais:** A importância de atributos (*Feature Importance*) permite auditar o peso de cada variável no modelo.
- **Legibilidade:** As regras de associação extraídas pelo *FP-Growth* são semanticamente claras, permitindo a tradução de padrões estatísticos em explicações de negócio compreensíveis a *stakeholders*.

5.2 Mitigação de Viés e Equidade

Para garantir justiça algorítmica, o tratamento de dados foi rigoroso:

- **Dados Ausentes:** Em vez de imputar médias artificiais em `days_since_prior_order` (o que criaria viés em primeiros pedidos), utilizamos uma variável sentinela (-1) e uma *flag* explícita de "primeiro pedido", permitindo que o modelo aprenda o comportamento distinto de novos clientes.
- **Heterogeneidade de Categorias:** Reconhecemos que taxas de recompra variam drasticamente entre departamentos (ex: perecíveis vs. artigos de beleza). Ao tratar o departamento como variável categórica, evitamos que o modelo negligencie padrões de nicho em favor dos produtos de alto giro.

5.3 Eficiência e Sustentabilidade

O uso de uma amostra estratificada (10% da base) foi um *trade-off* planejado para viabilizar experimentação ágil com menor pegada computacional. Adicionalmente, otimizamos o processamento através de:

- **Engenharia de Dados:** Uso de formatos binários (*Parquet*) e tipagem eficiente para reduzir a carga de memória.
- **Mineração Seletiva:** Aplicação de limiar mínimo de suporte no *FP-Growth* para descartar ruído e focar apenas em padrões estatisticamente robustos.

5.4 Trade-offs na Avaliação e Experiência do Usuário

A calibração do modelo final foi pautada pela experiência do usuário, reconhecendo que recomendações imprecisas geram fadiga e reduzem a confiança na plataforma.

Para minimizar o custo de "ruído" no *checkout*, optamos por um limiar de decisão conservador ($threshold = 0,08$). Isso prioriza recomendações de alta confiança em detrimento da abrangência, garantindo que o sistema apenas sugira produtos quando o sinal conjunto de hábito e afinidade for estatisticamente robusto.

Em suma, nossas diretrizes de IA Responsável não foram teóricas; elas ditaram decisões práticas de arquitetura (escolha do *LightGBM*), tratamento de dados (valor sentinela para novos clientes), eficiência de infraestrutura (amostragem) e calibração de resultados, assegurando um equilíbrio entre performance técnica e uso ético/sustentável.

6 Análise e Discussão dos Resultados Experimentais

A validação empírica do *pipeline* híbrido foi conduzida em duas frentes complementares: uma abordagem **estática** (predição de longo prazo baseada em hábitos consolidados do usuário) e uma abordagem **dinâmica** / *session-based* (predição contextual baseada no estado do carrinho em formação). Esta seção apresenta os resultados quantitativos de cada abordagem, a análise de importância de atributos (*feature importance*) que sustenta a interpretação dos resultados, e o estudo de ablação que isola a contribuição específica das regras de afinidade do FP-Growth.

6.1 Mineração de Padrões Frequentes: Validação da Hipótese 1

A aplicação do FP-Growth sobre o histórico de pedidos identificou blocos temáticos de produtos com forte associação de recompra conjunta, destacando-se receita/preparo (ex.: ingredientes complementares), variabilidade de categoria (hortifrúti/feira) e reposição de estoque (ex.: águas gaseificadas e iogurtes de linha), além de nichos específicos como abastecimento infantil.




Figura 9: Grafo de sinergia entre produtos segundo as regras de associação extraídas pelo FP-Growth (Top 25 associações por força de *lift*).

Esse resultado qualitativo confirma a Hipótese 1 (Sinergia de Recompra): existem conjuntos de produtos que tendem a ser recomprados em bloco, sustentando a decisão de transformar essas regras em atributos numéricos de afinidade (*fp_basket_max_confidence*, *fp_basket_sum_lift*, entre outros) para uso nos classificadores supervisionados.

6.2 Abordagem Estática (Longo Prazo)

Na modelagem estática, buscou-se prever a recompra no nível do par (*user_id*, *product_id*), baseando-se estritamente no perfil histórico consolidado do usuário e do produto, sem considerar o contexto da sessão de compra atual. O classificador LightGBM foi calibrado por meio de uma varredura de limiares de decisão (*threshold sweep*) para lidar com o desbalanceamento severo do problema, que é que a grande maioria dos pares usuário-produto do catálogo nunca é efetivamente recomprada na janela alvo.

O limiar ótimo identificado nessa etapa foi de **0,15**, resultando em um F1-Score de **0,3302** para a classe positiva (recompra).




Figura 10: Varredura de limiares de decisão para o modelo estático.




Figura 11: Matriz de confusão do classificador estático no limiar ótimo.

A análise de *Feature Importance* desta etapa revelou que as variáveis mais relevantes para a predição foram, na ordem, a taxa de recompra histórica do usuário (*user_reorder_rate_hist*), o número de produtos únicos adquiridos (*user_unique_products*) e o tamanho médio da cesta do usuário (*user_avg_basket_size*), todas de natureza puramente histórica/comportamental.




Figura 12: Importância de atributos no modelo estático híbrido.

Esse resultado é o ponto-chave da limitação identificada na abordagem estática: embora o F1-Score absoluto pareça relativamente alto nesta etapa intermediária, a inclusão dos atributos de afinidade do FP-Growth não trouxe agregação significativa de valor preditivo quando comparada às métricas puramente históricas e temporais, já que as variáveis *fp_** aparecem entre as últimas posições do *ranking* de importância. Isso significa que, na escala de longo prazo, a informação de afinidade entre produtos já está, em grande medida, implicitamente capturada pelas métricas de hábito do usuário, tornando-a redundante nesse cenário específico. Esse achado foi o principal motivador metodológico para a transição à abordagem *session-based*, descrita a seguir.

6.3 Abordagem Dinâmica (*Session-Based*)

Na modelagem baseada em sessão, a tarefa preditiva foi reformulada para um problema contextual: estimar se o usuário adicionará um determinado produto ao carrinho dada a configuração parcial da cesta atualmente em formação, e não apenas dado seu histórico consolidado. Essa reformulação exigiu reconstruir a tabela analítica no nível (*order_id*, *product_id*) e introduzir atributos dinâmicos de sessão (tamanho provisório da cesta, departamentos já representados, afinidade com os produtos já inseridos no carrinho atual).

Para isolar e validar o real impacto das regras de associação do FP-Growth nesse novo cenário, realizou-se um **estudo de ablação**, comparando duas configurações do mesmo classificador LightGBM:

1. **Rotina Pura (*baseline*):** utiliza exclusivamente as métricas de rotina temporal e histórica do usuário, sem qualquer atributo de afinidade;
2. **Modelo Híbrido (proposto):** adiciona ao *baseline* os atributos de afinidade derivados do FP-Growth (*fp_basket_max_lift*, *fp_basket_sum_confidence*, entre outros).

Os resultados comparativos no conjunto de teste (254.783 instâncias, das quais 6.655 são positivas) estão sumarizados na Tabela 1.

Tabela 1: Impacto dos atributos de afinidade do FP-Growth no modelo baseado em sessão.

Cenário de Modelagem	PR-AUC	Limiar Ótimo	F1-Score Máximo
Modelo de Rotina Pura (<i>Baseline</i>)	0,0787	0,12	0,0800
Modelo Híbrido (LightGBM + FP-Growth)	0,1010	0,08	0,1676




Figura 13: Varredura de *threshold* para o modelo *baseline* (sem FP-Growth); o pico de F1-Score ocorre próximo de *threshold* = 0,07–0,12, valor adotado para comparação direta com o modelo híbrido.




Figura 14: Curva *Precision-Recall* do modelo híbrido baseado em sessão. O PR-AUC de 0,1010 representa um ganho de aproximadamente 28% sobre o *baseline* (0,0787).




Figura 15: Matriz de confusão do modelo híbrido final no limiar ótimo (0,08). A calibração conservadora do *threshold* prioriza reduzir falsos positivos às custas de uma fração maior de falsos negativos.

A análise da Tabela 1 indica que a inclusão das regras de afinidade do carrinho atual mais que dobrou o desempenho do classificador, visto que o F1-Score subiu de 0,08 para 0,1676 (ganho de aproximadamente 109,5%), e o PR-AUC expandiu cerca de 28,3% (de 0,0787 para 0,1010). Esse resultado confirma empiricamente a Hipótese 1 (Sinergia de Recompra), especificamente no contexto de sessão: a intenção de curto prazo capturada pelas regras de associação corrige parte do viés estático do hábito puro de longo prazo, contrastando com o resultado nulo observado na abordagem estática (Seção 6.2).

A comparação direta entre as importâncias de atributos do modelo puro e do modelo híbrido reforça essa leitura:




Figura 16: Importância de atributos no modelo de rotina pura (sem FP-Growth), no contexto *session-based*.




Figura 17: Importância de atributos no modelo híbrido *session-based*. As variáveis *fp_** ocupam posições intermediárias de importância — superior à observada na abordagem estática (Figura 12).

Embora os atributos de hábito dominem a importância no modelo, as variáveis de afinidade do *FP-Growth* tornam-se significativamente mais relevantes no modelo baseado em sessão do que no estático. Isso confirma que o valor preditivo da afinidade é dependente do contexto: é pouco útil para o longo prazo, mas crucial para prever a inclusão de itens na cesta em formação.

A redução do limiar ótimo (de 0,12 para 0,08) reflete a maior capacidade discriminativa do modelo híbrido. Com a evidência adicional da afinidade, o classificador torna-se mais preciso, permitindo que utilizemos um limiar mais conservador para evitar a fadiga do usuário com recomendações de baixa confiança.

6.4 Limitações dos Resultados

Apesar dos ganhos, o modelo apresenta limitações inerentes:

- **Dominância do histórico:** Atributos de longo prazo prevalecem sobre as regras de afinidade, dificultando a recomendação de itens novos.
- **Problema de *cold start*:** Usuários ou produtos novos carecem de suporte estatístico, resultando em recomendações genéricas.
- **Estaticidade:** As regras de associação (*FP-Growth*) são globais e não capturam mudanças sazonais ou comportamentais abruptas do usuário.
- **Viés de amostragem:** A utilização de 10% dos dados, embora estratificada, pode ter atenuado padrões de comportamento de nicho (cauda longa).
- **Escalabilidade:** O desempenho na amostra não garante a mesma performance na base total (100%), sendo provável a necessidade de *fine-tuning* adicional para lidar com a maior variabilidade de dados em larga escala.

7 Conclusões e Perspectivas

Este projeto desenvolveu e avaliou um sistema híbrido para predição de compras recorrentes no Instacart. A transição de uma modelagem histórica estática para uma abordagem contextual baseada em sessão (*session-based*) provou ser o fator determinante para o sucesso, demonstrando que a predição da "próxima cesta" é um desafio dinâmico e dependente do contexto.

7.1 Principais Conquistas

A integração do *FP-Growth* ao *LightGBM* permitiu capturar hábitos de longo prazo e afinidades de curto prazo. O estudo de ablação confirmou que as *features* de associação atuam como refinadores essenciais, elevando o F1-Score em 109,5% no modelo de sessão. Uma contribuição central deste trabalho é a evidência metodológica de que a relevância de uma mesma variável depende criticamente do horizonte temporal e da formulação do problema.

7.2 Limitações e Trabalhos Futuros

Apesar dos ganhos, o sistema enfrenta desafios importantes: a forte dependência de histórico (*cold start*), estaticidade das regras de associação (falta de sazonalidade) e o viés decorrente do truncamento temporal dos dados.

Para trabalhos futuros, propõem-se adaptações nas áreas de:

1. **Escalabilidade:** Migração para *Apache Spark* para processar 100% da base.
2. **Dinamicidade:** Incorporação de sazonalidade explícita nas regras de afinidade.
3. **Cold Start:** Integração de filtragem baseada em conteúdo para novos usuários.

Por fim, este trabalho reafirma que, na predição de comportamento de compra, o sucesso do sistema depende menos do algoritmo isolado e mais da formulação contextual e dinâmica do problema.

Referências

- [1] ZAKI, M. J.; MEIRA JR., W. *Data Mining and Machine Learning: Fundamental Concepts and Algorithms*. 2. ed. Cambridge University Press, 2020. Disponível em: <https://dataminingbook.info/>.
- [2] Instacart. *Market Basket Analysis*. Kaggle, 2017. Disponível em: <https://www.kaggle.com/c/instacart-market-basket-analysis>.
- [3] KE, G. et al. *LightGBM: A Highly Efficient Gradient Boosting Decision Tree*. NIPS, 2017.
- [4] HAN, J.; PEI, J.; YIN, Y. *Mining frequent patterns without candidate generation*. ACM SIGMOD, 2000.

- [5] CHEN, T.; GUESTRIN, C. *XGBoost: A Scalable Tree Boosting System*. KDD, 2016.
- [6] RUDIN, C. *Stop explaining black box machine learning models for high stakes decisions*. Nature Machine Intelligence, 2019.