

Trabalho Prático 1

Proposta

Mineração de Padrões Frequentes

João Marcos Oliveira Neves
Matrícula: 2024008644
joao-neves@ufmg.br

Júlia Borba Fonseca de Souza
Matrícula: 2023117580
juliabfs@ufmg.br

Laura Martins Froede
Matrícula: 2023087877
froede@ufmg.br

Matheus Soares dos Santos de Freitas
Matrícula: 2024080043
matheussdsf@ufmg.br

23 de abril de 2026

Conteúdo

1	Contexto e Motivação	2
2	Objetivos e Problema a ser investigado	2
3	Metodologia Preliminar (Detalhamento via CRISP-DM)	2
4	Dados Pretendidos	3
5	Método Principal	4
5.1	Algoritmos	4
5.2	Métricas	4
5.3	Ferramental (Stack Tecnológica)	5
6	Diretrizes de IA Responsável	5
6.1	Explicabilidade (Explainability)	5
6.2	Privacidade e Segurança (Privacy and Security)	6

1 Contexto e Motivação

A recomendação de conteúdo em plataformas de streaming é um pilar central da economia da atenção. No entanto, recomendações baseadas apenas em algoritmos de "caixa-preta" (Deep Learning) muitas vezes carecem de interpretabilidade. Nesse contexto, a mineração de padrões frequentes oferece uma visão clara e baseada em regras sobre como itens e atributos (como gêneros e tags) se relacionam na perspectiva do usuário. Identificar esses padrões, portanto, permite não apenas sugerir filmes, mas entender "por que" eles estão conectados, otimizando catálogos e estratégias de marketing.

2 Objetivos e Problema a ser investigado

O problema central deste trabalho consiste na identificação de padrões ocultos de coocorrência em grandes volumes de dados de avaliação de filmes na web. Embora sistemas de recomendação modernos (como os baseados em Deep Learning) sejam eficientes na predição de notas, eles falham em fornecer regras lógicas e explicáveis que justifiquem por que certos itens ou atributos estão conectados na mente do consumidor. Assim, são formuladas três hipóteses a serem respondidas neste problema:

- **Hipótese 1 (Sinergia de Gêneros):** Quais combinações de gêneros (ex: *Sci-Fi* e *Horror*) possuem um suporte estatístico que justifique a criação de categorias híbridas em uma interface de usuário?
- **Hipótese 2 (Fidelidade de Perfil):** É possível identificar conjuntos de itens frequentes que caracterizam "comunidades de gosto" (ex: fãs de filmes franceses dos anos 60) sem o uso de dados demográficos, baseando-se apenas na coocorrência de avaliações positivas?
- **Hipótese 3 (Sinergia Temporal de Catálogo):** É possível identificar conjuntos de itens frequentes que transcendem as décadas de lançamento? Busca-se verificar se existe uma associação estatística forte entre filmes "clássicos" (ex: lançados antes de 1990) e lançamentos contemporâneos, indicando perfis de usuários que mantêm um consumo consistente de catálogo histórico em paralelo às novidades da plataforma.

Resolver essa tarefa é relevante, pois permite que plataformas de streaming organizem seu catálogo de forma mais intuitiva e criem campanhas de marketing mais precisas. Além disso, ao utilizar técnicas de mineração de padrões frequentes em vez de modelos de "caixa-preta", priorizamos a **Explicabilidade**, permitindo que os curadores de conteúdo validem e confiem nas associações encontradas pelo algoritmo.

3 Metodologia Preliminar (Detalhamento via CRISP-DM)

A execução da tarefa seguirá as fases do modelo CRISP-DM, garantindo um ciclo de análise sistemático e repetível:

Entendimento do Negócio (Business Understanding):

Foco em traduzir as necessidades de curadoria de conteúdo em problemas de mineração. O sucesso será medido pela capacidade de encontrar regras com *Lift* > 1 (indicando associação positiva), priorizando aquelas com valores superiores a 1.2 ou 1.5, que demonstram uma correlação mais significativa, e que sejam intuitivamente válidas para especialistas humanos.

Entendimento dos Dados (Data Understanding):

Envolverá uma Análise Exploratória (EDA) para mapear a esparsidade e a 'cauda longa' da matriz usuário-filme. Será verificada a distribuição estatística das notas (0.5 a 5.0) para validar o limiar de 'preferência positiva', além da identificação e filtragem de ruídos na frequência de tags. Também contará com análise da distribuição temporal do catálogo para garantir que a base possua volume representativo de filmes de diferentes décadas, permitindo a descoberta de associações entre eras.

Preparação dos Dados (Data Preparation):

- **Filtragem:** Seleção de avaliações ≥ 4.0 .
- **Agregação (Transformação Transacional):** Agrupamento de `movieIds` por `userId`, criando a estrutura de 'cestas de compras' necessária para o algoritmo.
- **Binarização de Gêneros:** Conversão da coluna `genres` (separada por *pipes*) em atributos binários para mineração de associações entre categorias.
- **Engenharia de Atributos:** Extração do ano de lançamento a partir do título dos filmes (presente no `movies.csv`) para categorizar os itens em décadas ou eras cinematográficas antes da mineração.

Modelagem (Modeling):

Aplicação do algoritmo FP-Growth sobre os dados preparados. Nesta fase, serão realizados múltiplos testes variando os parâmetros de `min_support` (para evitar padrões triviais ou raros) e `min_confidence`.

Avaliação (Evaluation):

Análise técnica das regras geradas. As regras serão confrontadas com as hipóteses iniciais. Por exemplo, para a hipótese de sinergia temporal, as regras serão validadas verificando se o algoritmo associa filmes de períodos distintos (ex: *The Godfather* → *The Irishman*).

4 Dados Pretendidos

O conjunto de dados a ser investigado é a base MovieLens 32M (ml-32m), recomendada para pesquisas recentes devido à sua atualidade e volume. A base compreende 32.000.204 avaliações e aproximadamente 2 milhões de tags aplicadas a 87.585 filmes por 200.948 usuários. O período de coleta abrange dados de janeiro de 1995 a outubro de 2023, permitindo uma análise temporal e de padrões de consumo muito mais robusta e contemporânea.

Base acessível pelo link: <https://grouplens.org/datasets/movielens/>

5 Método Principal

O método principal deste trabalho fundamenta-se na aplicação de técnicas de Mineração de Padrões Frequentes sobre a base MovieLens, visando validar as hipóteses formuladas e extrair regras de associação interpretáveis. O foco reside na descoberta de correlações estatísticas entre avaliações de filmes, permitindo a identificação de comportamentos de consumo em larga escala.

5.1 Algoritmos

Para a fase de Modelagem (CRISP-DM), propomos a utilização do algoritmo FP-Growth (*Frequent Pattern Growth*). Dada a magnitude da base (32M), a eficiência algorítmica é crítica. Dessa forma, a escolha pelo FP-Growth justifica-se pela sua capacidade de comprimir o conjunto de dados em uma estrutura de árvore (FP-Tree), evitando a geração custosa de candidatos para bases como o MovieLens, que possui quase 90 mil filmes diferentes. Ademais, serão aplicadas técnicas de amostragem ou filtros de suporte mais rigorosos para garantir a viabilidade computacional sem perda de representatividade estatística. Dessa forma, o processamento consistirá nas seguintes etapas:

1. Construção da árvore de frequências.
2. Extração de padrões frequentes que atingem o Suporte Mínimo.
3. Geração de regras que atingem a Confiança Mínima.

5.2 Métricas

A qualidade das regras será medida pelo tripé:

Suporte (s):

Indica a popularidade do conjunto de filmes na base total.

$$s(A \rightarrow B) = \frac{\text{frequência}(A, B)}{N}$$

Confiança (c):

Indica a probabilidade de um usuário avaliar o filme B, dado que ele avaliou o filme A.

$$c(A \rightarrow B) = \frac{\text{suporte}(A, B)}{\text{suporte}(A)}$$

Lift (l):

Mede o aumento na probabilidade de B ocorrer dado A, em comparação com a ocorrência de B ao acaso. Se $l > 1$, a regra é útil; se $l = 1$, os itens são independentes.

$$l(A \rightarrow B) = \frac{c(A \rightarrow B)}{s(B)}$$

5.3 Ferramental (Stack Tecnológica)

O projeto será desenvolvido em linguagem Python, utilizando bibliotecas como Pandas para a preparação dos dados. Neste contexto, trabalhar com 32M de registros no Pandas pode consumir muita memória RAM (provavelmente mais de 8GB-12GB apenas para carregar o CSV de `ratings`). Assim, será considerado o uso de Dask ou PySpark para a implementação do algoritmo FP-Growth por meio do processamento dos dados em partes.

6 Diretrizes de IA Responsável

Nesta seção, detalhamos a aplicação das diretrizes éticas e responsáveis no ciclo de mineração de dados, especificamente na interação com o modelo de linguagem (LLM) que auxiliará na interpretação dos padrões.

6.1 Explicabilidade (Explainability)

Pertinência:

Regras de associação ($A \rightarrow B$) são modelos inerentemente interpretáveis, mas frequentemente abstratos (listas de IDs). Em sistemas de recomendação, a explicabilidade é vital para que gestores de catálogo validem o nexos causal das sugestões, garantindo transparência no processo de decisão algorítmica.

Como explicitar nos prompts para a LLM:

No estágio de análise, a LLM será instruída com a seguinte diretriz: "Atue como um analista de negócios. Para cada regra de associação extraída, você não deve apenas listar IDs e métricas; você deve cruzar os dados com os arquivos `movies.csv` e `tags.csv` para traduzir o padrão técnico em uma justificativa semântica clara (ex: correlacionar gêneros ou estéticas visuais comuns)."

Aspectos da solução que se espera observar:

A transição de uma saída puramente quantitativa para uma narrativa qualitativa. A solução passará a fornecer o "porquê" por trás da associação, facilitando a comunicação entre a equipe técnica e os curadores de conteúdo.

Evidências esperadas:

Relatórios gerados pela LLM que identifiquem agrupamentos temáticos (ex: "Preferência por cinema cult europeu") em vez de meras listas de códigos numéricos.

Benefícios:

Aumento da confiança no sistema de recomendação e democratização do acesso aos dados para colaboradores de áreas não técnicas (marketing e editorial).

Trade-offs:

O esforço de tradução via LLM pode introduzir o risco de "alucinações" (interpretações errôneas dos metadados), o que exige que a explicabilidade seja sempre acompanhada das métricas originais (Confiança e Lift) para validação.

6.2 Privacidade e Segurança (Privacy and Security)

Pertinência:

A base MovieLens 32M, apesar de anonimizada, apresenta riscos de reidentificação. Devido à alta cardinalidade (quase 90 mil filmes), padrões de consumo raros podem funcionar como "assinaturas de comportamento" que permitem ataques de vinculação entre bases distintas.

Como explicitar nos prompts para a LLM:

A instrução de segurança será: "Atue como um filtro de proteção de privacidade. Analise as regras geradas e identifique aquelas que possuem um suporte extremamente baixo ($n < 5$). Recomende formalmente o descarte desses padrões para evitar o risco de exposição de comportamentos de nicho que possam levar à reidentificação de usuários individuais."

Aspectos da solução que se espera observar:

Um refinamento rigoroso no conjunto final de padrões, onde apenas tendências agregadas e estatisticamente seguras são mantidas, eliminando ruídos que possam comprometer o anonimato.

Evidências esperadas:

Logs de auditoria ou avisos emitidos pela LLM indicando quais regras foram suprimidas por não atingirem o limiar seguro de anonimato.

Benefícios:

Garantia de conformidade com princípios éticos de proteção de dados e redução de riscos legais e de privacidade inerentes ao tratamento de grandes volumes de dados pessoais (mesmo que pseudo-anonimizados).

Trade-offs:

A aplicação rigorosa dessa diretriz pode causar a perda de padrões de "cauda longa" (*long tail*), que embora raros, poderiam representar descobertas genuínas de nichos de mercado ainda não explorados.

Referências

- [1] Agrawal, R., & Srikant, R. (1994). Fast algorithms for mining association rules. In *Proceedings of the 20th International Conference on Very Large Data Bases (VLDB)*, pp. 487-499.
- [2] Han, J., Pei, J., & Yin, Y. (2000). Mining frequent patterns without candidate generation. *ACM SIGMOD Record*.
- [3] Harper, F. M., & Konstan, J. A. (2015). The MovieLens Datasets: History and Context. *ACM Transactions on Interactive Intelligent Systems (TiiS)*.