

Trabalho Prático 2

Proposta

Agrupamento (Clustering)

João Marcos Oliveira Neves

Matrícula: 2024008644

joao-neves@ufmg.br

Júlia Borba Fonseca de Souza

Matrícula: 2023117580

juliabfs@ufmg.br

Laura Martins Froede

Matrícula: 2023087877

froede@ufmg.br

Matheus Soares dos Santos de Freitas

Matrícula: 2024080043

matheussdsf@ufmg.br

16 de maio de 2026

Conteúdo

1	Contexto e Motivação	2
2	Objetivos e Problema a ser investigado	2
3	Metodologia Preliminar (Detalhamento via CRISP-DM)	2
4	Dados Pretendidos	3
5	Método Principal	4
5.1	Algoritmos	4
5.2	Métricas	4
5.3	Ferramental (Stack Tecnológica)	5
6	Diretrizes de IA Responsável	5
6.1	Explicabilidade (Explainability)	5
6.2	Justiça e Mitigação de Viés (Fairness)	6

1 Contexto e Motivação

No setor financeiro e bancário, a compreensão do comportamento dos clientes é fundamental para a mitigação de riscos, personalização de limites de crédito e detecção de anomalias. Modelos tradicionais de classificação supervisionada frequentemente exigem rótulos pré-definidos (como adimplente/inadimplente), falhando em capturar as nuances sutis dos hábitos de consumo diários. Nesse cenário, o agrupamento (clustering) surge como uma abordagem não supervisionada poderosa, capaz de descobrir grupos homogêneos de correntistas a partir de padrões multidimensionais de gastos, pagamentos e uso do limite disponível. A identificação desses perfis permite que as instituições financeiras ofereçam intervenções proativas, adaptem suas políticas de crédito e criem estratégias de atendimento focadas na saúde financeira do cliente.

2 Objetivos e Problema a ser investigado

O problema central deste trabalho consiste na identificação de perfis comportamentais ocultos e não rotulados em uma base de dados de titulares de cartões de crédito. Busca-se extrair agrupamentos que diferenciem os clientes com base na dinâmica financeira interna de suas contas, mitigando a opacidade de análises agregadas simples. Para guiar esta investigação, formulam-se três hipóteses principais:

- **Hipótese 1 (Segmentação por Modalidade de Compra):** É possível separar de forma clara grupos de clientes que utilizam o cartão primordialmente para compras à vista (*one-off purchases*) daqueles que dependem majoritariamente do parcelamento, permitindo a personalização de ofertas de juros?
- **Hipótese 2 (Identificação de Comportamento de Risco):** O algoritmo é capaz de isolar um grupo específico de usuários caracterizado por saldos devedores persistentemente altos, saques frequentes em dinheiro (*cash advance*) e pagamentos mínimos da fatura, mapeando perfis de potencial endividamento?
- **Hipótese 3 (Sinergia entre Limite e Utilização):** Existe um agrupamento de clientes com altos limites de crédito que subutilizam a ferramenta, contrastando com um grupo de baixo limite que opera constantemente próximo ao teto disponível? A descoberta desses grupos justificaria políticas automatizadas de realocação de limite.

A resolução desta tarefa prioriza a **Explicabilidade**, garantindo que cada cluster descoberto possua uma assinatura centroidal clara que possa ser justificada aos analistas de risco e de negócios da instituição.

3 Metodologia Preliminar (Detalhamento via CRISP-DM)

A execução do projeto seguirá as fases do ciclo CRISP-DM adaptadas para o aprendizado não supervisionado:

Entendimento do Negócio (Business Understanding):

Tradução dos padrões de agrupamento em estratégias de segmentação financeira. O sucesso será medido pela capacidade de gerar clusters com alto índice de separabilidade e que possuam interpretações de negócio acionáveis (ex: campanhas específicas para diminuir o risco de *default*).

Entendimento dos Dados (Data Understanding):

Realização de Análise Exploratória (EDA) para estudar a distribuição de atributos numéricos altamente assimétricos (como o saldo devedor e o volume de saques). Será avaliada a correlação entre o limite de crédito e o volume total de compras, além de mapear o percentual de valores ausentes em variáveis críticas como o valor mínimo de pagamento.

Preparação dos Dados (Data Preparation):

- **Imputação de Dados:** Tratamento de valores ausentes na coluna de pagamentos mínimos através de técnicas de mediana condicional ao grupo.
- **Tratamento de Outliers:** Avaliação de clientes com movimentações atípicas milionárias (remoção ou isolamento em clusters de anomalia).
- **Normalização/Escalonamento:** Aplicação de transformações como *StandardScaler* ou *MinMaxScaler*, crucial para algoritmos baseados em distância (K-Means), dado que os atributos variam de frequências (0 a 1) a valores monetários (milhares de dólares).
- **Engenharia de Atributos:** Criação de métricas de proporção, como a razão entre o saldo devedor e o limite de crédito (*Credit Utilization Ratio*).
- **Redução de Dimensionalidade:** Aplicação da Análise de Componentes Principais (PCA) para reduzir o espaço amostral original de 18 variáveis para um conjunto menor de componentes principais que expliquem a maior parte da variância dos dados. Isso mitigará a maldição da dimensionalidade, otimizará o cálculo de distâncias do K-Means e do DBSCAN, e viabilizará a visualização gráfica dos agrupamentos.

Modelagem (Modeling):

Aplicação de múltiplos algoritmos de agrupamento, incluindo K-Means (como baseline global), DBSCAN (para identificação de outliers e clusters de densidade arbitrária) e Agrupamento Hierárquico. O número ideal de clusters (k) será determinado via Método do Cotovelo (*Elbow Method*) e Gráfico de Silhueta.

Avaliação (Evaluation):

Validação cruzada dos clusters utilizando métricas internas (Coeficiente de Silhueta e Índice Davies-Bouldin) combinada com uma validação externa/qualitativa das regras de negócio que definem cada grupo gerado.

4 Dados Pretendidos

O conjunto de dados utilizado será o **Credit Card Dataset for Clustering** (disponível publicamente em repositórios como o Kaggle). A base contém o comportamento de uso de

aproximadamente 8.950 titulares de cartões de crédito ativos durante um período de 6 meses. O dataset é composto por 18 variáveis comportamentais, incluindo:

- **BALANCE:** Saldo pendente na conta para compras.
- **PURCHASES:** Montante total de compras realizadas. e as colunas de controle de transações como **ONEOFF_PURCHASES**, **INSTALLMENTS_PURCHASES**, **CASH_ADVANCE** e **CREDIT_LIMIT**.

O tamanho moderado da base permite experimentações rápidas de algoritmos densos no ambiente do Google Colab sem comprometer a memória RAM disponível.

Base acessível pelo link: <https://www.kaggle.com/datasets/arjunbhasin2013/ccdata>

5 Método Principal

O arcabouço metodológico visa segmentar os usuários de forma robusta e garantir que a estrutura dos agrupamentos reflita o comportamento real de mercado.

5.1 Algoritmos

Diferentes paradigmas de clustering serão contrastados para garantir a robustez da solução:

1. **K-Means:** Algoritmo de partição baseado em centroides. Minimiza a variância dentro dos clusters (Inércia).
2. **DBSCAN:** Algoritmo baseado em densidade. Importante para isolar clientes com comportamentos extremamente atípicos (ruídos/fraudes) que distorceriam os centroides do K-Means.
3. **Agrupamento Hierárquico:** Algoritmo baseado em conectividade que constrói uma hierarquia de clusters. Será utilizado para visualizar a taxonomia multiescalar dos perfis de clientes sem a necessidade de definir o número de clusters a priori, servindo como uma validação visual complementar ao K-Means.

5.2 Métricas

A qualidade e estabilidade dos agrupamentos serão avaliadas por:

Coefficiente de Silhueta (S):

Mede o quão próximo um ponto está do seu próprio cluster em comparação com os outros clusters. Varia de -1 a 1.

$$S = \frac{b - a}{\max(a, b)}$$

Onde a é a distância média intra-cluster e b é a distância média para o cluster vizinho mais próximo.

Índice Davies-Bouldin (DB):

Avalia a similaridade entre os clusters baseada na distância entre seus centroides e o tamanho dos clusters. Valores menores indicam melhor separação.

5.3 Ferramental (Stack Tecnológica)

O desenvolvimento será realizado em Python no ambiente Google Colab. Serão utilizadas as bibliotecas `pandas` e `numpy` para manipulação de dados, `scikit-learn` para implementação dos algoritmos de clustering e transformações de escala, e `matplotlib/seaborn` para visualização tridimensional e plotagem de mapas de calor das características dos centroides.

6 Diretrizes de IA Responsável

A segmentação automatizada de perfis financeiros traz responsabilidades éticas cruciais que serão monitoradas através de interações estruturadas com Modelos de Linguagem (LLM).

6.1 Explicabilidade (Explainability)

Pertinência:

Algoritmos de clustering dividem o espaço multidimensional de forma puramente matemática. Sem uma tradução semântica, os perfis gerados tornam-se caixas-pretas estatísticas inutilizáveis para equipes de risco e de crédito humanas.

Como explicitar nos prompts para a LLM:

A instrução de modelagem exigirá: "Atue como um Especialista em Ciências Comportamentais Aplicadas a Finanças. Dado o vetor de centroides de cada cluster gerado, traduza as médias numéricas em personas financeiras detalhadas (ex: 'O Consumidor Consciente Parcelador' ou 'O Usuário Dependente de Saques Emergenciais'), justificando o perfil com base nas variáveis estruturais."

Aspectos da solução que se espera observar:

A transformação de matrizes numéricas abstratas de centroides em perfis comportamentais e narrativas de negócios inteligíveis para tomadores de decisão não técnicos.

Evidências esperadas:

Mapeamento claro e visual dos agrupamentos matemáticos em personas financeiras detalhadas e perfis de negócio documentados pela LLM.

Benefícios:

Aumento da transparência dos critérios de segmentação e facilitação da validação humana sobre o comportamento de agrupamento do algoritmo.

Trade-offs:

Simplificar grupos estatísticos complexos em "personas" pode esconder subgrupos minoritários ou nuances comportamentais dentro de um mesmo cluster, introduzindo riscos de generalização excessiva.

6.2 Justiça e Mitigação de Viés (Fairness)

Pertinência:

Agrupamentos baseados em saldos devedores e capacidade de pagamento mínimo podem criar loops de feedback discriminatórios. Se um cluster rotular sistematicamente indivíduos de menor poder aquisitivo em grupos de "altíssimo risco", o algoritmo pode justificar a redução automática de seus limites, agravando sua vulnerabilidade econômica.

Como explicitar nos prompts para a LLM:

A LLM será guiada pela seguinte restrição: "Atue como um ombudsman de IA Ética. Analise a distribuição de limites e saldos nos clusters gerados. Avalie se o modelo está penalizando desproporcionalmente grupos com menor capacidade de pagamento com rótulos de risco excessivos e sugira formas de balancear a interpretação do cluster para evitar a exclusão financeira injusta."

Aspectos da solução que se espera observar:

A identificação de possíveis vieses socioeconômicos induzidos pelas variáveis de adimplência e a formulação de salvaguardas que impeçam a penalização automática de perfis vulneráveis.

Evidências esperadas:

Relatório de impacto de equidade gerado pela LLM, identificando se houve viés de severidade algorítmica sobre perfis de baixa renda.

Benefícios:

Alinhamento do modelo com as melhores práticas de concessão de crédito justa e prevenção de discriminação indireta (*proxy discrimination*).

Trade-offs:

Mitigar o viés de risco nos rótulos pode diminuir a agressividade comercial da segmentação, exigindo que a instituição financeira aceite uma margem de incerteza ligeiramente maior em prol da equidade social.

Referências

- [1] MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. In *Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability*, pp. 281-297.
- [2] Ester, M., Kriegel, H. P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. In *Proceedings of the 2nd International Conference on Knowledge Discovery and Data Mining (KDD)*, pp. 226-231.

- [3] Rouseeuw, P. J. (1987). Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53-65.