

Trabalho Prático 3

Proposta

Classificação Supervisionada

João Marcos Oliveira Neves

Matrícula: 2024008644

joao-neves@ufmg.br

Júlia Borba Fonseca de Souza

Matrícula: 2023117580

juliabfs@ufmg.br

Laura Martins Froede

Matrícula: 2023087877

froede@ufmg.br

Matheus Soares dos Santos de Freitas

Matrícula: 2024080043

matheussdsf@ufmg.br

6 de junho de 2026

Conteúdo

1	Contexto e Motivação	2
2	Objetivos e Problema a ser investigado	2
3	Metodologia Preliminar (Detalhamento via CRISP-DM)	3
4	Dados Pretendidos	4
5	Método Principal	4
5.1	Algoritmo Selecionado e Justificativa	4
5.2	Métricas	5
5.3	Ferramental (Stack Tecnológica)	5
6	Diretrizes de IA Responsável	5
6.1	Justiça e Mitigação de Viés (Fairness)	5
6.2	Explicabilidade (Explainability)	6

1 Contexto e Motivação

No âmbito das políticas públicas, concessão de crédito, recrutamento automatizado e sistemas de recomendação socioeconômica, a capacidade de prever faixas de renda com base em características demográficas e profissionais é uma ferramenta central para a tomada de decisão. Contudo, diferentemente do cenário não supervisionado, os modelos de classificação supervisionada herdam diretamente as desigualdades históricas e os preconceitos estruturais refletidos nos rótulos das bases de treino. O uso de algoritmos complexos de alta performance pode perpetuar discriminações contra minorias, automatizando injustiças sob um pretexto de neutralidade matemática. Nesse contexto, a tarefa de classificação exige um tratamento metodológico rigoroso focado na auditoria de viés, de modo que o modelo preditivo não atue como uma caixa-preta reprodutora de desigualdades, mas sim como um sistema cujas decisões possam ser escrutinadas, explicadas e mitigadas sob critérios éticos.

2 Objetivos e Problema a ser investigado

O problema central deste trabalho consiste em construir e avaliar um classificador preditivo binário robusto para prever se a renda anual de um cidadão supera ou não o patamar de U\$ 50.000 com base em dados censitários, monitorando e mitigando ativamente o viés algorítmico. Busca-se investigar o comportamento de um preditor não linear de alta capacidade diante de atributos sensíveis explícitos e suas variáveis correlacionadas (*proxies*). Para guiar esta investigação, formulam-se três hipóteses principais:

- **Hipótese 1 (Impacto dos Atributos Sensíveis Diretos):** A inclusão explícita de variáveis como gênero (*sex*) e raça (*race*) induz o classificador a estabelecer barreiras discriminatórias diretas, penalizando subgrupos minoritários históricos na classificação da faixa de alta renda?
- **Hipótese 2 (Discriminação por Proxies):** A simples remoção cega dos atributos sensíveis diretos é insuficiente para garantir a equidade do sistema, pois variáveis ocupacionais (*occupation*) e estruturais de relacionamento (*relationship*) atuam como *proxies* que reconstroem as desigualdades demográficas de forma indireta dentro das fronteiras de decisão?
- **Hipótese 3 (Comprometimento de Métricas por Desbalanceamento):** O desbalanceamento severo da variável-alvo mascara deficiências de generalização do modelo, tornando a acurácia global uma métrica enganosa que penaliza o desempenho sobre a classe minoritária de alta renda?

A resolução desta tarefa prioriza a **Justiça e Mitigação de Viés** e a **Explicabilidade**, garantindo a transparência dos fatores de decisão preditiva através de análises de relevância local e global.

3 Metodologia Preliminar (Detalhamento via CRISP-DM)

A execução do projeto seguirá as fases do ciclo CRISP-DM adaptadas para o aprendizado supervisionado com restrições de equidade:

Entendimento do Negócio (Business Understanding):

Definição dos critérios de sucesso econômicos e sociais do modelo. O objetivo é maximizar a capacidade preditiva da faixa de renda limitando o impacto dispar entre grupos protegidos, garantindo que a solução seja viável para políticas de concessão justa.

Entendimento dos Dados (Data Understanding):

Realização de Análise Exploratória (EDA) para quantificar o desbalanceamento da variável-alvo e mapear a distribuição de renda entre diferentes gêneros, faixas etárias e raças. Identificação e contagem de valores ausentes mascarados (como o caractere de interrogação "?") em colunas categóricas cruciais.

Preparação dos Dados (Data Preparation):

- **Tratamento de Nulos Ocultos:** Conversão dos caracteres "?" para NaN e posterior aplicação de imputação estatística (como preenchimento pela moda condicional à classe ou criação de categoria exclusiva para dados ausentes).
- **Engenharia de Recursos e Cardinalidade:** Agrupamento e redução de categorias esparsas de alta cardinalidade, com atenção especial à variável de país de origem (*native-country*), para evitar matrizes excessivamente esparsas.
- **Codificação Categórica (Encoding):** Aplicação de técnicas de codificação adequadas para variáveis nominais e ordinais, como *One-Hot Encoding* para atributos não ordenados.
- **Transformação de Escala:** Aplicação de transformações logarítmicas ou padronização robusta em atributos contínuos altamente discrepantes, tais como ganhos e perdas de capital (*capital-gain* e *capital-loss*).

Modelagem (Modeling):

Treinamento, otimização e ajuste de hiperparâmetros (via *GridSearchCV* ou *RandomizedSearchCV*) do algoritmo selecionado, mapeando suas curvas de aprendizado para mitigar cenários de *overfitting*.

Avaliação (Evaluation):

Validação do desempenho por meio de validação cruzada estratificada. A análise abandonará a acurácia isolada e focará em *F1-Score*, precisão, revocação (*Recall*) e na área sob a curva ROC (*AUC – ROC*). Paralelamente, o grupo avaliará métricas de equidade para medir a taxa de aceitação e falsos positivos entre os subgrupos protegidos.

4 Dados Pretendidos

O conjunto de dados utilizado será o clássico **Adult Census Income** (derivado do Censo de 1994 dos EUA e hospedado publicamente no Kaggle e no Repositório UCI). A base contém informações socioeconômicas brutas de 32.561 indivíduos e 15 atributos numéricos e categóricos. A variável-alvo é binária (**income**), indicando se a renda anual é maior que U\$ 50.000 (>50K) ou menor/igual (<=50K). Entre as principais variáveis comportamentais e demográficas presentes, destacam-se:

- **age** e **education-num**: Idade do indivíduo e nível educacional quantificado de forma numérica.
- **workclass** e **occupation**: Regime de trabalho e setor de ocupação profissional.
- **sex** e **race**: Gênero e raça autodeclarados, tratados de forma estrita como os atributos sensíveis centrais para a auditoria de viés.
- **capital-gain** e **capital-loss**: Ganhos e perdas financeiras de capital externo.

Base acessível pelo link: <https://www.kaggle.com/datasets/uciml/adult-census-income>

5 Método Principal

O arcabouço metodológico visa construir um classificador preditivo estatisticamente confiável, avaliando explicitamente as fronteiras de decisão e mitigando preconceitos estruturais dos dados.

5.1 Algoritmo Selecionado e Justificativa

O grupo optou por utilizar exclusivamente o algoritmo **XGBoost (Extreme Gradient Boosting)** como o classificador do projeto.

A escolha justifica-se tecnicamente por se tratar de uma implementação de Gradient Boosting altamente otimizada, baseada em comitês de árvores de decisão que operam de forma sequencial corrigindo os erros dos preditores anteriores. O XGBoost possui uma capacidade nativa superior para capturar relações não lineares e interações complexas entre atributos numéricos e categóricos esparsos, tornando-o o estado da arte para dados tabulares mistos como os do censo. Além disso, o algoritmo possui controle interno de regularização (**L1** e **L2**) para evitar *overfitting* e lida de forma robusta com o desbalanceamento de classes através do parâmetro de peso dos gradientes.

Sob a ótica de IA Responsável, a escolha de um modelo de conjunto de alta complexidade matemática justifica-se por impor o cenário perfeito de desafio analítico: o algoritmo entrega o teto de desempenho preditivo do problema, mas opera originalmente como uma "caixa-preta". Isto obriga o grupo a rejeitar interpretações simplistas e a adotar, de forma mandatória, métodos pós-hoc avançados de explicabilidade (como os valores SHAP) para auditar as decisões. Esse desenho metodológico enriquece o trabalho, permitindo contrastar a máxima eficiência técnica com os limites da interpretabilidade humana e do impacto díspar.

5.2 Métricas

A eficácia do classificador será avaliada sob a ótica balanceada de desempenho e equidade:

Métricas Globais de Classificação:

Focadas na avaliação do acerto preditivo geral, contornando o desbalanceamento da base:

$$\text{F1-Score} = 2 \times \frac{\text{Precisão} \times \text{Recall}}{\text{Precisão} + \text{Recall}}$$

Onde a Precisão mede a fidelidade das predições de alta renda e o *Recall* (Revocação) mede a sensibilidade do modelo em encontrar as pessoas de alta renda de fato existentes.

Métrica de Equidade (Impacto Díspar):

Razão entre a probabilidade de predição positiva (>50K) para o grupo não protegido (*GP*) contra o grupo protegido (*G*). Valores distantes de 1 indicam viés de seleção:

$$\text{Impacto Díspar} = \frac{P(\hat{Y} = 1 \mid G = \text{protegido})}{P(\hat{Y} = 1 \mid GP = \text{não protegido})}$$

5.3 Ferramental (Stack Tecnológica)

O ambiente de desenvolvimento será o Python no Google Colab. A manipulação de dados será executada via `pandas` e `numpy`. A modelagem utilizará a biblioteca `xgboost`, integrada ao ecossistema do `scikit-learn` para os pipelines de pré-processamento e validação. A explicabilidade do modelo será extraída por meio da biblioteca pós-hoc `SHAP` (SHapley Additive exPlanations). Gráficos e matrizes de confusão serão gerados via `seaborn` e `matplotlib`.

6 Diretrizes de IA Responsável

A predição de renda individual carrega fortes impactos éticos e sociais, demandando o monitoramento contínuo das decisões por meio de auditorias estruturadas apoiadas por Modelos de Linguagem (LLM).

6.1 Justiça e Mitigação de Viés (Fairness)

Pertinência:

Classificadores treinados com o censo de 1994 tendem a reproduzir o cenário socioeconômico da época, onde mulheres e negros apresentavam proporções de renda significativamente menores devido a barreiras históricas. O XGBoost corre o risco de converter essa correlação histórica em uma regra rígida de exclusão preditiva atual.

Como explicitar nos prompts para a LLM:

"Atue como um Auditor Independente de Viés Algorítmico. Analise as taxas de falsos negativos e o Impacto Díspar entre os subgrupos de gênero e raça para o modelo XGBoost treinado. Avalie se o algoritmo está perpetuando discriminação de forma

direta ou por meio de variáveis *proxy* e proponha uma estratégia de pós-processamento (como ajuste de limiar de decisão) para equalizar as oportunidades."

Aspectos da solução que se espera observar:

A quantificação exata da disparidade de aprovação de alta renda entre os subgrupos demográficos e o isolamento de variáveis profissionais que camuflam o viés demográfico.

Evidências esperadas:

Relatório comparativo de equidade exibindo os índices de impacto díspar e paridade de erro antes e após intervenções de mitigação técnica.

Benefícios:

Prevenção da automação de preconceitos históricos, alinhando o modelo de classificação com princípios modernos de justiça social e conformidade ética.

Trade-offs:

Forçar a paridade estatística nas previsões do XGBoost entre grupos historicamente desiguais pode reduzir a precisão geral do modelo, gerando um custo técnico aceitável em prol da equidade algorítmica.

6.2 Explicabilidade (Explainability)

Pertinência:

O XGBoost, por ser um modelo de conjunto baseado em árvores impulsionadas, não possui uma equação linear ou regras simples que possam ser lidas diretamente por humanos. Negar um benefício ou classificar um cidadão como de baixa renda sem justificativas claras fere o direito à explicação e inviabiliza auditorias de controle.

Como explicitar nos prompts para a LLM:

"Atue como um Especialista em Inteligência Artificial Explicável (XAI). Com base nos valores SHAP globais e nos gráficos de dependência parcial gerados para o XGBoost, construa uma justificativa textual clara e acessível ao público geral explicando quais fatores profissionais (ex: nível educacional) ou de capital foram determinantes para a classificação de renda efetuada."

Aspectos da solução que se espera observar:

A tradução das importâncias de recursos abstratas e das interações não lineares mapeadas pelo SHAP em uma hierarquia inteligível de causas socioeconômicas reais.

Evidências esperadas:

Sumarização interpretável dos fatores determinantes do modelo para tomadores de decisão humanos e relatórios de auditoria local baseados nos valores Shapley.

Benefícios:

Transparência absoluta sobre os critérios de corte do classificador complexo, permitindo que falhas lógicas e distorções matemáticas do modelo sejam identificadas de forma inteligível.

Trade-offs:

Depender de aproximações pós-hoc (como SHAP) para explicar o XGBoost traz um custo computacional elevado e introduz uma camada adicional de interpretação que pode simplificar marginalmente a complexidade real do modelo.

Referências

- [1] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785-794.
- [2] Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems (NeurIPS)*, pp. 4765-4774.
- [3] Barocas, S., & Selbst, A. D. (2016). Big data's disparate impact. *California Law Review*, 104, 671-732.